

# Metody Obliczeniowe w Nauce i Technice

## 5. Aproksymacja

Marian Bubak, Katarzyna Rycerz

Department of Computer Science  
AGH University of Science and Technology  
Krakow, Poland  
[kzajac@agh.edu.pl](mailto:kzajac@agh.edu.pl)  
[dice.cyfronet.pl](http://dice.cyfronet.pl)

### Contributors

Paweł Urban

Jakub Ptak

Łukasz Janeczko



# Outline

- 1 Aproksymacja
- 2 Aproksymacja średniokwadratowa
- 3 Aproksymacja jednostajna
- 4 Wielomiany Czebyszewa (Chebyshev Polynomials)
- 5 Wzór rekurencyjny Clenshawa

# Aproksymacja

Aproksymacja:

- przybliżanie lub zastępowanie funkcji za pomocą innej funkcji
- jest ogólniejsza niż interpolacja

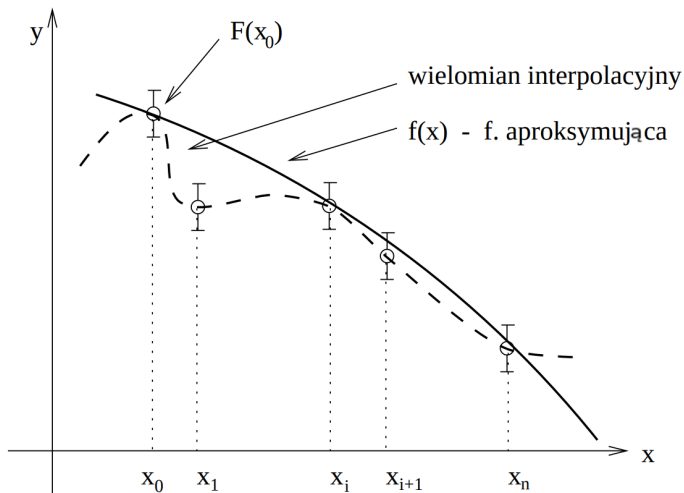
# Funkcja aproksymowana i aproksymująca


$F(x)$  - to funkcja aproksymowana i może być:

- znana
- podana jako tablica wartości eksperymentalnych (z błędami, ale wtedy interpolacja nie ma sensu)

$f(x)$  - to funkcja aproksymująca = przybliżenie  $F(x)$

# Aproksymacja średniokwadratowa





# Postawienie problemu

## Dane:

- $(x_i, y_i = F(x_i)), i = 0, 1, \dots, n$ , czyli mamy  $(n+1)$  węzłów
- układ funkcji bazowych:  $\varphi_j(x), j = 0, 1, \dots, m$ .

## Szukamy wielomianu uogólnionego:

$$f(x) = \sum_{j=0}^m a_j \varphi_j(x)$$

czyli  $\{a_j\}_{j=0}^m$ , dla których:

$$\min \| F(x) - f(x) \| = \min \sum_{i=0}^n w(x_i) \underbrace{\left[ F(x_i) - \sum_{j=0}^m a_j \varphi_j(x_i) \right]^2}_{\text{odchylenie}}$$

$H(a_0, a_1, \dots, a_m)$

**Pochodzenie nazwy:** postać normy  $F(x)$  na  $[a, b]$

# Przypadek ciągły

Dla przypadku ciągłego minimalizujemy wartość całki:

$$\min \int_a^b w(x)[F(x) - f(x)]^2 dx$$

⇒ aproksymacja średniokwadratowa funkcji ciągłych

$w(x)$  - funkcja wagowa,  $w(x) \geq 0$

Zwykle:  $w(x_i) \sim \frac{1}{[\text{błąd } F(x_i)]^2}$  lub  $w(x) = 1$



# Współczynniki wielomianu uogólnionego

Współczynniki  $\{a_j\}$  znajdujemy z warunku:

$\frac{\partial H}{\partial a_k} = 0, k = 0, 1, \dots, m \Rightarrow$  układ  $(m + 1)$  równań liniowych o  $(m + 1)$  niewiadomych

$$\frac{\partial H}{\partial a_k} = -2 \cdot \sum_{i=0}^n w(x_i) \left[ F(x_i) - \sum_{j=0}^m a_j \varphi_j(x_i) \right] \varphi_k(x_i) = 0; k = 0, 1, \dots, m$$

Powyższy układ równań zwany jest układem normalnym.

# Aproksymacja wielomianowa

Dane:

funkcje bazowe  $\rightarrow$  ciąg jednomianów  $\varphi_j(x) = x^j, j = 0, 1, \dots, m$

funkcja aproksymująca:  $f(x) = \sum_{j=0}^m a_j \varphi_j(x) = \sum_{j=0}^m a_j x^j$

$F(x)$  - zadana na zbiorze dyskretnym  $\{x_i\}, i = 0, 1, \dots, n$

Szukamy takich współczynników  $a_j$ , że :

$$\min \sum_{i=0}^n w(x_i) [F(x_i) - f(x_i)]^2$$

Układ normalny:

$$\sum_{i=0}^n w(x_i) \left[ F(x_i) - \sum_{j=0}^m a_j x_i^j \right] x_i^{k \leftarrow \frac{\partial f}{\partial a_k}} = 0, k = 0, 1, \dots, m$$

$$\sum_{i=0}^n w(x_i) x_i^k \sum_{j=0}^m a_j x_i^j = \sum_{i=0}^n w(x_i) F(x_i) x_i^k, k = 0, 1, \dots, m$$

$$\sum_{j=0}^m \underbrace{\left( \sum_{i=0}^n w(x_i) x_i^{j+k} \right)}_{g_{k,j}} a_j = \sum_{i=0}^n \underbrace{w(x_i) F(x_i) x_i^k}_{b_k}$$

W postaci macierzowej:

$$\begin{pmatrix} \sum w_i & \sum w_i x_i & \sum w_i x_i^2 & \dots & \sum w_i x_i^m \\ \sum w_i x_i & \sum w_i x_i^2 & \sum w_i x_i^3 & \dots & \sum w_i x_i^{m+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum w_i x_i^m & \sum w_i x_i^{m+1} & \sum w_i x_i^{m+2} & \dots & \sum w_i x_i^{2m} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \sum w_i F_i \\ \sum w_i F_i x_i \\ \vdots \\ \sum w_i F_i x_i^m \end{pmatrix}$$

$$\underline{G \cdot A = B}$$

**Jeżeli:**

①  $x_0, x_1, \dots, x_n$  - są różne

②  $m \leq n$

to  $\det G \neq 0 \rightarrow$  układ ma jedno rozwiązanie.

# W praktyce

- $m \ll n$  (korzystamy z dużej ilości informacji)
- $m$  - wysoki - by dobrze przybliżyć funkcję
- $m$  - niski - by wygładzić błędy
- zwykle  $m \leq 6$

# Ortogonalność funkcji

## Definicja ortogonalności funkcji

Funkcje  $f(x)$  i  $g(x)$  nazywamy ortogonalnymi na dyskretnym zbiorze punktów  $\{x_i, i = 0, 1, \dots, n\}$ , jeżeli:

$$\sum_{i=0}^n f(x_i) \cdot g(x_i) = 0, \sum_{i=0}^n [f(x_i)]^2 > 0, \sum_{i=0}^n [g(x_i)]^2 > 0$$

# Ortogonalność ciągów

## Definicja ortogonalności ciągów

Ciągi funkcyjne  $\{\varphi_k(x)\}$  nazywamy ortogonalnymi na dyskretnym zbiorze punktów  $\{x_i\}$ , jeżeli:

$$\sum_{i=0}^n \varphi_j(x_i) \varphi_k(x_i) = \begin{cases} 0 & j \neq k \\ > 0 & j = k \end{cases} \rightarrow (*)$$

(\*) - nie wszystkie  $x_i$  to miejsca zerowe.



# Aproksymacja średniokwadratowa wielomianami ortogonalnymi

Dla wielomianów ortogonalnych układ normalny:

$$\sum_{i=0}^n w(x_i) \left[ F(x_i) - \sum_{j=0}^m a_j \varphi_j(x_i) \right] \varphi_k(x_i) = 0, k = 0, 1, \dots, m$$

$$\sum_{i=0}^n w(x_i) F(x_i) \varphi_k(x_i) = \sum_{i=0}^n w(x_i) \varphi_k(x_i) \sum_{j=0}^m a_j \varphi_j(x_i)$$

$$\sum_{i=0}^n w(x_i) F(x_i) \varphi_k(x_i) = \sum_{j=0}^m a_j \sum_{i=0}^n w(x_i) \varphi_k(x_i) \varphi_j(x_i)$$

$$\sum_{i=0}^n w(x_i) F(x_i) \varphi_k(x_i) = a_k \sum_{i=0}^n w(x_i) \varphi_k^2(x_i)$$

→ macierz staje się diagonalna → znika:

- złe uwarunkowanie
- konieczność ponownego rozwiązywania układu normalnego przy zmianie stopnia wielomianu aproksymującego

Najczęściej stosowane wielomiany ortogonalne:

- Czebyszewa  $T_j(x)$
- Legendre'a  $P_n(x)$  (→ zwłaszcza dla  $w(x_i) = 1$ )

# Aproksymacja średniokwadratowa funkcjami sklejanymi

Możliwa jest aproksymacja średniokwadratowa funkcjami sklejanymi.

Przykład: [https://pl.wikibooks.org/wiki/Metody\\_numeryczne\\_fizyki/Aproksymacja](https://pl.wikibooks.org/wiki/Metody_numeryczne_fizyki/Aproksymacja)

# Wielomiany Legendre'a

Określone wzorem

$$P_n(x) = \frac{1}{n! \cdot 2^n} \frac{d^n}{dx^n} [(x^2 - 1)^n], x \in [-1, 1], n = 0, 1, \dots$$

Spełniają wzór rekurencyjny (dla  $n \geq 1$ ):

$$(2n + 1) \cdot x \cdot P_n(x) = (n + 1)P_{n+1}(x) + n \cdot P_{n-1}(x)$$

$$P_0 = 1$$

$$P_1(x) = x$$


$$P_2(x) = \frac{1}{2}(3x^2 - 1)$$

$$P_3(x) = \frac{1}{2}(5x^3 - 3x)$$

$$P_4(x) = \frac{1}{8}(35x^4 - 30x^2 + 3)$$

$$\vdots$$

$$P_n(1) = 1; |P_n(x)| \leq 1, x \in [-1, 1]$$



# Własności

Wielomiany Legendre'a spełniają zależność:

$$P_n(-x) = (-1)^n \cdot P_n(x)$$

spełniają równania różniczkowe:

$$\frac{d}{dx} \left[ (1 - x^2) \frac{dP_n(x)}{dx} \right] + n(n+1)P_n(x) = 0$$

**Ortogonalność:**

$$\int_{-1}^1 P_n(x) P_m(x) dx = \begin{cases} 0, & m \neq n \\ \frac{2}{2n+1}, & m = n \end{cases}$$

# Aproksymacja jednostajna

Dla  $F(x)$  określonej na  $[a, b]$  szukamy  $f(x)$ :

$$\min \|F(x) - f(x)\| = \min \underbrace{\sup_{x \in [a, b]} |F(x) - f(x)|}_{\text{norma Czebyszewa}}$$

## Twierdzenie Weierstrassa

Jeżeli  $F(x) \in C^0[a, b]$ , to dla każdego  $\varepsilon > 0$  można dobrać  $n(\varepsilon)$  takie, że istnieje  $W_n(x) : |F(x) - W_n(x)| < \varepsilon$

Wniosek:  $F(x)$  można aproksymować jednostajnie wielomianami.

Szukamy  $a_i$ :

$$W_n(x) = \sum_{i=0}^n a_i x^i \text{ aby } \min E_n,$$

$$E_n = \max_{x \in [a, b]} |F(x) - W_n(x)|$$



### Twierdzenie Borela

Jeśli  $F(x) \in C^0[a, b]$ ,  $n$  - naturalna, to istnieje  $W_n(x)$  będący najlepszym przybliżeniem  $F(x)$ .

### Twierdzenie Czebyszewa

Wielomian  $W_n(x)$  będący najlepszym przybliżeniem  $F(x)$  jest tylko jeden.

# Metoda szeregów potęgowych - szereg Taylora

Prostą metodą aproksymacji jednostajnej jest metoda szeregów potęgowych t.j. używamy pierwszych  $n+1$  wyrazów szeregu Taylora:

$$W_n(x) = \sum_{k=0}^n \frac{F^{(k)}(x_0)}{k!} (x - x_0)^k$$

oszacowanie błędu aproksymacji  $\rightarrow$  reszta Lagrange'a:

$$F(x) - W_n(x) = \frac{F^{n+1}(\eta)}{(n+1)!} (x - x_0)^{n+1}, \eta \in [a, b]$$

# Przybliżenia Padé

**ang.** Padé approximation, rational function approximation

Aproksymujemy funkcję  $F(x)$  za pomocą funkcji wymiernej  $r(x)$ .  
Funkcja wymierna  $r(x)$  stopnia  $N = n + m$  ma postać:

$$r(x) = \frac{p(x)}{q(x)} = \frac{p_0 + p_1x + \dots + p_nx^n}{q_0 + q_1x + \dots + q_mx^m}$$

- nieredukowalna ( $p, q$  - są względnie pierwsze - nie mają wspólnych dzielników)
- określona w  $x = 0 \Rightarrow q_0 \neq 0, \Rightarrow q_0 = 1$  (zwykle)
- do określenia  $N + 1 = n + m + 1$  współczynników

# Technika aproksymacji Padé

Jest to sposób określenia  $\{p_i, q_j\}, i = 0, \dots, n, j = 0, \dots, m$  przy zadanych  $n, m$

$$F(x) - r(x) = F(x) - \frac{p(x)}{q(x)} = \frac{F(x) \cdot q(x) - p(x)}{q(x)}$$

Niech  $F(x) = \sum_{i=0}^{\infty} a_i \cdot x^i \rightarrow$  szereg Maclaurina

$$F(x) - r(x) = \frac{\sum_{i=0}^{\infty} a_i x^i \cdot \sum_{i=0}^m q_i x^i - \sum_{i=0}^n p_i x^i}{q(x)}$$

Należy dobrać  $p_0, p_1, \dots, p_n$  i  $q_1, \dots, q_m$  tak, aby rozwinięcia  $F(x)$  i  $r(x)$  w szereg Maclaurina były jak najbardziej zgodne czyli możliwie najwięcej pochodnych  $F(x)$  i  $r(x)$  w  $x = 0$  było równych:

$$F^{(k)}(0) - r^{(k)}(0) = 0, k = 0, 1, \dots, N$$

$$w(x) = ax^3 + bx^2 + cx + d, w(0) = d \text{ i } w(0) = 0 \rightarrow d = 0$$

$$w'(x) = 3ax^2 + 2bx + c, w'(0) = c \text{ i } w'(0) = 0 \rightarrow c = 0$$

$$w''(x) = 6ax + 2b, w''(0) = 2b \text{ i } w''(0) = 0 \rightarrow b = 0$$

$$w'''(x) = 6a, w'''(0) = 6a \text{ i } w'''(0) = 0 \rightarrow a = 0$$

To znaczy, że licznik:

$$(a_0 + a_1x + \dots)(1 + q_1x + \dots + q_mx^m) - (p_0 + p_1x + \dots + p_nx^n)$$

nie powinien mieć wyrazów stopnia  $\leq N$ . Dla uproszczenia zapisu:

$$p_{n+1} = p_{n+2} = \dots = p_N = 0 \text{ i } q_{m+1} = q_{m+2} = \dots = q_N = 0$$

Wtedy współczynniki:  $\sum_{i=0}^k a_i q_{k-i} - p_k$  powinny być równe 0, a znalezienie  $p(x)$  i  $q(x)$  polega na rozwiązaniu układu równań liniowych:

$$\sum_{i=0}^k a_i q_{k-i} - p_k = 0; k = 0, 1, \dots, N$$

$$(a_0 + a_1 x + \dots) (1 + q_1 x + q_2 x^2 + \dots + q_m x^m)$$

Współczynnik przy  $x^0$   $a_0$

przy  $x^1$   $a_0 q_1 + a_1$

przy  $x^k$   $\sum_{i=0}^k a_i q_{k-i}$

# Typowy przykład

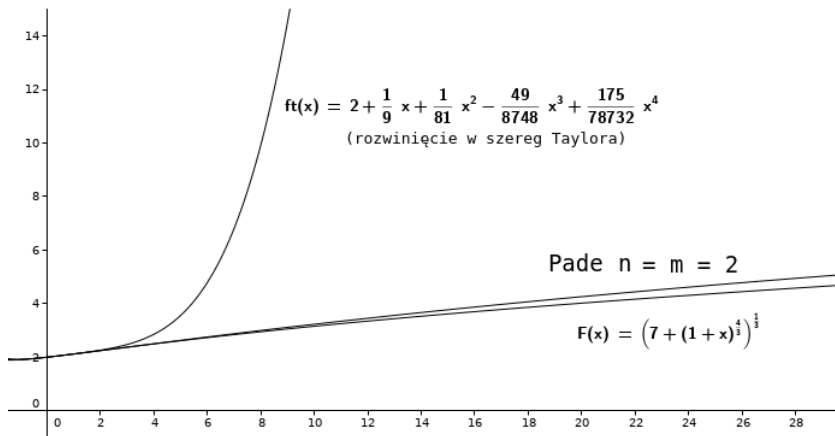
$$F(x) = [7 + (1+x)^{\frac{4}{3}}]^{\frac{1}{3}} \approx 2 + \frac{1}{9}x + \frac{1}{81}x^2 - \frac{49}{8748}x^3 + \frac{175}{78732}x^4 + \dots$$

## Uwagi

- w praktyce:  $N = n + m$  - ustalone: 
$$\begin{cases} n = m \\ n = m + 1 \end{cases}$$



Aproksymacja Pade dla funkcji  $F(x) = (7 + (1+x)^{\frac{4}{3}})^{\frac{1}{3}}$



# Wielomiany Czebyszewa

Reprezentacja trygonometryczna.

Wiemy, że  $\forall x \in [-1, 1] \exists \varphi \in [0, \pi] : \cos \varphi = x$

Dla  $x \in [-1, 1]$  podstawmy  $\varphi = \arccos x$  i definiujemy wielomiany Czebyszewa:

$$T_n(x) = \cos[n \cdot \arccos x]$$

Z tożsamości trygonometrycznej:

$$\cos(n\varphi) + \cos[(n-2)\varphi] = 2 \cos[(n-1)\varphi] \cdot \cos \varphi$$

$$\cos(n\varphi) = 2 \cos[(n-1)\varphi] \cdot \cos \varphi - \cos[(n-2)\varphi]$$

Wynika relacja rekurencyjna:

$$T_n(x) = 2xT_{n-1}(x) - T_{n-2}(x), \text{ dla } n \geq 2$$

## Relacja rekurencyjna

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_2(x) = 2x^2 - 1$$

$$T_3(x) = 4x^3 - 3x$$

$$T_4(x) = 8x^4 - 8x^2 + 1$$

$$T_5(x) = 16x^5 - 20x^3 + 5x$$

$$\vdots$$


$$T_n(x) = 2xT_{n-1}(x) - T_{n-2}(x), \text{ dla } n \geq 2$$

### Czynnik wiodący

Czynnik wiodący w  $T_n(x)$  jest to czynnik przy najwyższej potędze  $x$ , czyli  $2^{n-1}$  (dla  $n \geq 1$ )

# Symetria

$$T_k(-x) = (-1)^k \cdot T_k(x)$$



## Miejsca zerowe $T_n(x)$ - węzły Czebyszewa

$T_n(x)$  ma w  $[-1, 1]$   $n$  miejsc zerowych:

$$T_n(x) = \cos(\underbrace{n \arccos x}_{\alpha}) = 0$$

wtedy, gdy:

$$\cos(n \cdot \alpha) = 0 \text{ dla } n \cdot \alpha = (2k + 1) \cdot \frac{\pi}{2}, \alpha \in [0, \pi]$$

czyli

$$\alpha = \frac{2k + 1}{n} \cdot \frac{\pi}{2}, k = 0, 1, \dots, n - 1$$

$$\arccos x_k = \frac{2k + 1}{n} \cdot \frac{\pi}{2}, k = 0, 1, \dots, n - 1$$

Tak więc miejsca zerowe:

$$x_k = \cos\left(\frac{2k + 1}{n} \cdot \frac{\pi}{2}\right), k = 0, 1, \dots, n - 1$$

# Ortogonalność

## Przypadek ciągły

$$\int_{-1}^1 \frac{T_i(x) \cdot T_j(x)}{\sqrt{1-x^2}} dx = \begin{cases} 0 & i \neq j \\ \frac{\pi}{2} & i = j \neq 0 \\ \pi & i = j = 0 \rightarrow \text{repr. tryg.} \end{cases}$$

## Przypadek dyskretny $x_k$ - miejsca zerowe $T_{m+1}(x)$

$$\sum_{k=0}^m T_i(x_k) T_j(x_k) = \begin{cases} 0 & i \neq j \\ \frac{m+1}{2} & i = j \neq 0 \\ m+1 & i = j = 0 \end{cases}$$

# Własność minimaksu wielomianów Czebyszewa

## Twierdzenie o normie $T_n(x)$

Ze wszystkich wielomianów stopnia  $n \geq 1$  z czynnikiem wiodącym równym 1 najmniejszą normę maksymalną w  $[-1, 1]$

$$\|W_n\|_{\infty} = \max_{x \in [a, b]} |W_n|$$

ma wielomian  $2^{1-n} \cdot T_n(x)$ . Wynosi ona  $2^{1-n}$


## Dowód (nie wprost)

Założmy, że  $\exists p_n(x)$  o współczynniku wiodącym = 1 taki, że:

$$\forall_{x \in [-1, 1]} |p_n(x)| < 2^{1-n}$$

Możemy zdefiniować punkty ekstremalne, czyli takie dla których


$$|T_n(x)| = 1$$





Ma  $n=4$   
4 przedział

$$\begin{aligned}
 x_0 &= \cos 0 = 1 && \left. \begin{array}{l} 1 \text{ przedział} \\ 2 \text{ przedział} \end{array} \right\} \\
 x_1 &= \cos \frac{\pi}{4} = \frac{1}{\sqrt{2}} \\
 x_2 &= \cos \frac{\pi}{2} = 0 && \left. \begin{array}{l} 3 \text{ przedział} \\ 4 \text{ przedział} \end{array} \right\} \\
 x_3 &= \cos \frac{3\pi}{4} = -\frac{1}{\sqrt{2}} \\
 x_4 &= \cos \pi = -1
 \end{aligned}$$



$x'_k$  jest punktem ekstremalnym jeśli  $T_n(x'_k) = (-1)^k$ ,  
analogicznie jak dla przypadku miejsc zerowych zachodzi:

$$x'_k = \cos \frac{k\pi}{n}, \quad k = 0, 1, \dots, n$$

Dla  $\forall x'_k$  powinno zachodzić:

$$p_n(x'_0) < 2^{1-n} \cdot T_n(x'_0),$$

$$p_n(x'_1) > 2^{1-n} \cdot T_n(x'_1),$$

$$p_n(x'_2) < 2^{1-n} \cdot T_n(x'_2),$$

$\dots$ , aż do  $x'_n$

$$\Rightarrow \text{czyli wielomian } [p_n(x) - 2^{1-n} \cdot T_n(x)]$$

powinien zmieniać znak w każdym z przedziałów:

$$(x'_{k+1}, x'_k), \quad k = \underbrace{n-1, n-2, \dots, 1, 0}_{n \text{ przedziałów} \rightarrow n \text{ zer}}$$

$\Rightarrow$  czyli powinien być wielomianem stopnia  $n$  w  $[-1, 1]$ ,

ale  $p_n(x)$  i  $2^{1-n} \cdot T_n(x)$  mają ten sam współczynnik wiodący,

Zatem ich różnica jest stopnia  $n-1$  i mamy sprzeczność.

# Interpolacja węzłami $T_{n+1}(x)$

$W_n(x)$  - wielomian interpolacyjny (Lagrange'a) stopnia  $n$ ;  
 $W_n(x_k) = f(x_k), k = 0, 1, \dots, n$  Ze wzoru na błąd interpolacji Lagrange'a mamy:

$$f(x) = W_n(x) + E_n(x); E_n(x) = \frac{f^{(n+1)}(c)}{(n+1)!} \underbrace{\prod_{i=0}^n (x - x_i)}_{\omega_{n+1}}, c \in [x_0, x_n]$$

Przez optymalny wybór rozmieszczenia węzłów  $x_k$  można zminimalizować  $\max |\omega_{n+1}(x)|$

**Rozwiązanie:** Wprost z własności minimaksu - wielomianem mającym najmniejszy  $\max|\omega_{n+1}(x)|$  jest  $2^{-n} \cdot T_{n+1}(x)$ , który możemy przedstawić przy pomocy jego zer  $x_i$  jako:

$$2^{-n} \cdot T_{n+1}(x) = \prod_{i=0}^n (x - x_i)$$

Czyli jako węzły interpolacji należy wziąć zera wielomianu  $T_{n+1}(x)$

$$x_k = \cos\left(\frac{2k+1}{n+1} \frac{\pi}{2}\right), k = 0, 1, \dots, n$$


### Uwaga


Transformacja przedziału  $x \in [a, b] \rightarrow t \in [-1, 1]$

$$x = \frac{b-a}{2}t + \frac{a+b}{2}$$

Na następnych slajdach porównanie:

- interpolacja z równoodległymi węzłami (11 węzłów)
- interpolacja z węzłami Czebyszewa  $\rightarrow$  zera  $T_{11}(x)$





# Interpolujący wielomian Czebyszewa

$T_n(x)$  zachowują się równomiernie w  $[-1, 1]$ ;  $\min = -1$ ,  $\max = 1$  -  
**ważna własność**

Do utworzenia wielomianu interpolacyjnego można wykorzystać liniową kombinację:

$$W_n(x) = \sum_{j=0}^n c_j T_j(x)$$

Współczynniki  $c_j$  wyznaczamy z własności ortogonalności dla przypadku dyskretnego:

Jeśli  $x_k = \cos\left(\frac{2k+1}{n+1} \frac{\pi}{2}\right)$  są zerami  $T_{n+1}(x)$ ,  $k = 0, 1, \dots, n$  to:

$$\sum_{k=0}^n T_i(x_k) T_j(x_k) = \begin{cases} 0 & i \neq j \\ n+1 & i = j = 0 \\ \frac{n+1}{2} & i = j \neq 0 \end{cases}$$



## Wyznaczanie współczynników $c_i$

Korzystamy z warunku interpolacji:

$$f(x_k) = \sum_{j=0}^n c_j T_j(x_k)$$

Następnie dla każdego węzła mnożymy ten warunek obustronnie przez  $T_i(x_k)$  i składamy je w sumę:

$$f(x_k) = \sum_{j=0}^n c_j T_j(x_k) \quad \left| T_i(x_k) \right| \quad \sum_{k=0}^n$$

$$\sum_{k=0}^n f(x_k) T_i(x_k) = \sum_{j=0}^n c_j \underbrace{\sum_{k=0}^n T_i(x_k) T_j(x_k)}_{\text{ortogonalność}}$$

## Współczynniki $c_i$

Z warunku ortogonalności znikają wszystkie składniki  $\sum_{j=0}^n$  poza  $j = i$  i mamy:

$$\sum_{k=0}^n f(x_k) T_i(x_k) = c_i \underbrace{\sum_{k=0}^n T_i(x_k) T_i(x_k)}_{\text{ortogonalność}}$$

$$\sum_{k=0}^n f(x_k) T_0(x_k) = c_0(n+1) \text{ czyli } c_0 = \frac{1}{n+1} \sum_{k=0}^n f(x_k) T_0(x_k)$$

$$\sum_{k=0}^n f(x_k) T_i(x_k) = c_i \frac{n+1}{2} \text{ czyli } c_i = \frac{2}{n+1} \sum_{k=0}^n f(x_k) T_i(x_k)$$


dla  $i = 1, \dots, n$

Współczynniki są od siebie niezależne ! (pomocny: alg. Clenshawa)

Jeśli wyliczymy ich mniej - aproksymacja. Porównaj (slajd 17)

$$\sum_{i=0}^n w(x_i) F(x_i) \varphi_k(x_i) = a_k \sum_{i=0}^n w(x_i) \varphi_k^2(x_i)$$

# Analogia do wektorów $R^2$



W przykładowej bazie wektorów nieortogonalnych  
Zmiana  $d$  pociąga za sobą zmianę  $a=c+d$

**Współczynniki są zależne!**

$$\vec{w} = 3\vec{x} + 1\vec{y}$$

$$\vec{w} = a\vec{x} + b\vec{y}$$

$$\vec{z} = \vec{x} + \vec{y}$$

$$\vec{w} = c\vec{x} + d\vec{z}$$

$$\vec{w} = c\vec{x} + d(\vec{x} + \vec{y})$$

$$\vec{w} = \underbrace{(c+d)}_a \vec{x} + d\vec{y}$$

## Szacowanie błędu aproksymacji

Maksymalna odległość między "kolejnymi" aproksymacjami w bazie wielomianów Czebyszewa liczona przy użyciu normy aproksymacji jednostajnej  $\sup_{x \in [a,b]} |g(x) - f(x)|$  to:

$$f(x) = a_n \cdot T_n(x) + a_{n-1} \cdot T_{n-1}(x) + \dots + a_1 \cdot T_1(x) + a_0 \cdot T_0(x)$$

$$g(x) = a_{n-1} \cdot T_{n-1}(x) + \dots + a_1 \cdot T_1(x) + a_0 \cdot T_0(x)$$

$$|g(x) - f(x)| < |a_n| \cdot \underbrace{|T_n(x)|}_{\max 1} \leq |a_n|$$

Kolejne współczynniki mówią nam o błędach przybliżenia!  
 Jeśli współczynniki wyższych rzędów maleją  $\rightarrow$  wskaźnik, że funkcja "nadaje się" do aproksymacji wielomianami.

# Co przy pomiarach?

Problem: Trzeba znać wartości funkcji aproksymowanej w węzłach Czebyszewa.

Możliwe (alternatywne) rozwiązania:

- mierzyć w węzłach Czebyszewa
- mierzyć wystarczająco gęsto
- użyć aproksymacji wielomiami Czebyszewa w "złych" punktach, ale z dobranymi wagami mówiącymi o jakości tych punktów.

# Aproksymacja wielomianami Czebyszewa (p. ciągły)

Aproksymacja jednostajna:  $\min_{x \in [a,b]} |F(x) - f(x)|$

Baza  $T_i(x)$  wygodna, bo  $T_i(x)$  - równomierne w  $[-1, 1]$

Pierwszy sposób (podobnie jak w metodzie szeregów potęgowych):

**$F(x)$  zastępujemy sumą częściową:**

$$F(x) \approx \sum_{j=0}^n c_j T_j(x)$$

z  $c_j$  wyznaczonymi z warunku ortogonalności w przypadku ciągłym

$$F(x) = \sum_{j=0}^{\infty} c_j T_j(x) \quad \left| \cdot \frac{T_i(x)}{\sqrt{1-x^2}} \right| \int_{-1}^1 dx$$

$$c_0 = \frac{1}{\pi} \int_{-1}^1 \frac{F(x) T_0(x) dx}{\sqrt{1-x^2}} \quad c_i = \frac{2}{\pi} \int_{-1}^1 \frac{F(x) T_i(x) dx}{\sqrt{1-x^2}}, i = 1, \dots, n$$

Drugi sposób analogiczny do aproksymacji Pade.

Tworzymy wyrażenia wymierne postaci:

$$T_{n,k}(x) = \frac{\sum_{i=0}^n a_i T_i(x)}{\sum_{i=0}^k b_i T_i(x)}$$

o  $a_i$ ,  $b_i$  dobranych tak, licznik wyrażenia

$$F(x) - T_{n,k}(x) = \frac{[\sum_{j=0}^{\infty} c_j T_j(x)] \cdot [\sum_{i=0}^k b_i T_i(x)] - \sum_{i=0}^n a_i T_i(x)}{\sum_{i=0}^k b_i T_i(x)}$$

był równy kombinacji liniowej wielomianów Czebyszewa o wskaźnikach większych od  $k+n$ .

Dla zainteresowanych: [https://pl.wikibooks.org/wiki/Metody\\_numeryczne\\_fizyki/Aproksymacja](https://pl.wikibooks.org/wiki/Metody_numeryczne_fizyki/Aproksymacja)

# Clenshaw's recurrence formula

Elegancki i efektywny sposób sumowania wyrazów spełniających pewien wzór rekurencyjny:

$$f(x) = \sum_{k=0}^N c_k F_k(x)$$

przy czym  $c_k$  znane oraz  $F(x)$  - spełnia wzór rekurencyjny:

$$F_{n+1}(x) = \alpha(n, x) \cdot F_n(x) + \beta(n, x) \cdot F_{n-1}(x)$$

gdzie:  $\alpha(n, x), \beta(n, x)$  - pewne funkcje

Przykładem takiej sumy jest suma stosowana przy wyznaczaniu współczynników dla interpolacji Czebyszewa.



Jak działa?

Określamy rekurencyjnie pomocnicze zmienne

$y_k, k = N, N - 1, \dots, 1$  (downward order;  $k$  - decreasing) jako:

$$y_{N+2} = y_{N+1} = 0, y_k(x) = \alpha(k, x) \cdot y_{k+1} + \beta(k+1, x) \cdot y_{k+2} + c_k$$

Stąd wyliczamy zależność:

$$c_k = y_k - \alpha(k, x) \cdot y_{k+1} - \beta(k+1, x) \cdot y_{k+2}$$

Po podstawieniu otrzymujemy:

$$\begin{aligned}
 f(x) &= \sum_{k=N}^0 [y_k - \alpha(k, x)y_{k+1} - \beta(k+1, x)y_{k+2}] \cdot F_k(x) = \\
 &= [ \quad y_N \quad - \quad \quad \quad 0 \quad - \quad \quad 0 \quad ] F_N(x) \\
 &+ [ \quad y_{N-1} \quad - \quad \alpha(N-1, x) \cdot y_N \quad - \quad \quad 0 \quad ] F_{N-1}(x) \\
 &\quad \dots \quad \quad \quad \dots \quad \quad \quad \dots \\
 &+ [ \quad y_8 \quad - \quad \alpha(8, x)y_9 \quad - \quad \beta(9, x)y_{10} \quad ] F_8(x) \\
 &+ [ \quad y_7 \quad - \quad \alpha(7, x)y_8 \quad - \quad \beta(8, x)y_9 \quad ] F_7(x) \\
 &+ [ \quad y_6 \quad - \quad \alpha(6, x)y_7 \quad - \quad \beta(7, x)y_8 \quad ] F_6(x) \\
 &+ [ \quad y_5 \quad - \quad \alpha(5, x)y_6 \quad - \quad \beta(6, x)y_7 \quad ] F_5(x) \\
 &\quad \dots \quad \quad \quad \dots \quad \quad \quad \dots \\
 &+ [ \quad y_2 \quad - \quad \alpha(2, x)y_3 \quad - \quad \beta(3, x)y_4 \quad ] F_2(x) \\
 &+ [ \quad y_1 \quad - \quad \alpha(1, x)y_2 \quad - \quad \beta(2, x)y_3 \quad ] F_1(x) \\
 &+ [ \quad y_0 \quad - \quad \alpha(0, x)y_1 \quad - \quad \beta(1, x)y_2 \quad ] F_0(x) =
 \end{aligned}$$

"Czerwone" składniki dają:

$$y_8[F_8(x) - \alpha(7, x)F_7(x) - \beta(7, x)F_6(x)]$$

ponieważ z założenia  $F_8(x) = \alpha(7, x)F_7(x) + \beta(7, x)F_6(x)$  to "czerwone" składniki się zerują.

Jedynymi składnikami, które pozostaną są te w "dolnym lewym trójkącie" czyli:

$$(*)y_1F_1(x) + [y_0 - \alpha(0, x)y_1]F_0(x)$$

Ponieważ  $c_0 = y_0 - \alpha(0, x)y_1 - \beta(1, x)y_2$  to (\*) można przekształcić do:

$$F_1(x)y_1 + \beta(1, x)y_2F_0(x) + c_0F_0(x)$$

Tak więc wyznaczanie  $f(x) = \sum_{k=0}^N c_k F_k(x)$   
dla  $F_k(x)$ :  $F_{n+1}(x) = \alpha(n, x) \cdot F_n(x) + \beta(n, x) \cdot F_{n-1}(x)$   
sprowadza się do:

- ❶ wyznaczenia  $y_1$  i  $y_2$  z formuły rekurencyjnej:

$$\begin{cases} y_{N+2} = y_{N+1} = 0 \\ y_k(x) = \alpha(k, x) \cdot y_{k+1} + \beta(k+1, x) \cdot y_{k+2} + c_k \end{cases}$$

- ❷ obliczenia sumy

$$f(x) = \beta(1, x) \cdot y_2(x) \cdot F_0(x) + y_1(x) \cdot F_1(x) + c_0 \cdot F_0(x)$$

## Clenshaw's recurrence in upward direction:

W zależności od różnic pomiędzy

$$\begin{array}{ll} F_k(x) & \text{dla małych i dużych } k \\ c_k & \text{dla małych i dużych } k \end{array}$$

może mieć znaczenie, czy współczynniki  $y_k$  są liczone od większych do mniejszych  $k$ , czy na odwrót.

Wykrywanie utraty dokładności:

$\beta(1, x) \cdot y_2 \cdot F_0$  oraz  $y_1 \cdot F_1$  - przeciwnych znaków i prawie równe

Wtedy stosować **Clenshaw's recurrence in upward direction**:

$$y_{-2} = y_{-1} = 0$$

$$y_k = \frac{1}{\beta(k+1, x)} [y_{k-2} - \alpha(k, x)y_{k-1} - c_k], k = 0, 1, \dots, N-1$$

$$f(x) = c_N F_N(x) - \beta(B, x) F_{N-1}(x) y_{N-1} - F_N(x) y_{N-2}$$

[https://www.ams.org/journals/mcom/1955-09-051/  
S0025-5718-1955-0071856-0/S0025-5718-1955-0071856-0.  
pdf](https://www.ams.org/journals/mcom/1955-09-051/S0025-5718-1955-0071856-0/S0025-5718-1955-0071856-0.pdf)